

# Predição do Valor de Imóveis em São Paulo

Regressão linear implementada com NumPy para prever preços de venda e aluguel de imóveis paulistanos.



# Objetivo do Projeto



## Previsão de Preços

Prever valores de **venda e aluguel** de imóveis em São Paulo com regressão linear



## Dataset Kaggle

**13.600 imóveis** coletados em abril de 2019 no município de São Paulo



## Métrica MAE

Avaliação pelo **Erro Absoluto Médio** — interpretável em reais



## Ferramentas

pandas, numpy e matplotlib — **sem bibliotecas prontas de ML**





- Tamanho (m<sup>2</sup>), quartos, banheiros, suítes e vagas de garagem
- Amenidades: elevador, mobiliado, piscina, novo

- Distrito, latitude e longitude


- Preço de venda **ou** aluguel – tratados em modelos separados

# Distribuição de Preços

## O que os histogramas revelam

A distribuição de preços — tanto de venda quanto de aluguel — apresenta **assimetria positiva**: a maioria dos imóveis se concentra em faixas de preço mais acessíveis, enquanto uma minoria de imóveis de alto padrão forma uma **cauda longa à direita**.

- ❏ A cauda longa puxa a média para cima, tornando a mediana uma medida mais representativa do mercado típico.



# Tamanho vs Preço: Relação Positiva



## Relação Linear Clara

Imóveis maiores (em m<sup>2</sup>) tendem consistentemente a apresentar preços mais elevados — o scatter plot revela uma tendência linear bem definida.



## Dispersão em Imóveis Grandes

Propriedades com maior metragem mostram **maior variação de preço**: fatores como localização e acabamento diferenciam imóveis de tamanho similar.



## Implicação para o Modelo

O tamanho(Size) se consolida como a variável preditora mais poderosa da regressão linear.





# Padrões Geográficos de Valorização




O que o mapa revela

Ao colorir cada imóvel por faixa de preço no mapa de São Paulo, emergem **clusters geográficos nítidos** de valorização — evidenciando que o endereço é um preditor fundamental.

- **Pinheiros e Vila Mariana:** concentram os imóveis de maior valor, especialmente na região centro-sul
- **Periferia:** preços consistentemente mais baixos, com menor dispersão
- **Latitude e longitude** entram no modelo como features numéricas para capturar esses padrões

# Variáveis Mais Correlacionadas com Preço



## Interpretando a Matriz de Correlação

A matriz de correlação (heatmap) permite identificar quais variáveis têm relação linear mais forte com o preço — orientando a seleção de features.

- **Size (Tamanho):** correlação mais forte — principal preditor do modelo
- **Condo (Condomínio):** segunda correlação mais relevante com o preço
- **Quartos, banheiros e garagem:** correlação moderada e complementar

❏ Variáveis muito correlacionadas entre si (multicolinearidade) podem afetar a interpretabilidade dos pesos do modelo.



# Metodologia: Regressão Linear Manual

1

## Seleção de Features

Condo, Size, Rooms, Toilets, Suites, Parking, Elevator, Furnished, Swimming Pool, New, Latitude, Longitude

2

## Divisão Treino / Teste

80% dos dados para treino e 20% para teste — garantindo avaliação em dados não vistos

3

## Equação Normal com NumPy

Implementação manual via `np.linalg.lstsq` — sem scikit-learn ou bibliotecas de ML

4

## Dois Modelos Separados

Um modelo dedicado para **venda** e outro para **aluguel**, respeitando as distribuições distintas



# Resultados: Erro Médio Absoluto (MAE)

## Como interpretar o MAE

O MAE representa, em média, em quantos reais o modelo erra ao prever o preço de um imóvel. Quanto menor, melhor a precisão das previsões.



### Modelo de Venda

MAE indica o erro médio em reais para predição do preço de venda



### Modelo de Aluguel

MAE indica o erro médio em reais para predição do valor de aluguel

O gráfico de **valores reais vs. valores previstos** permite visualizar visualmente a qualidade das previsões: pontos próximos da diagonal indicam bom ajuste do modelo.

# Variáveis Mais Influentes



## Aumentam o Preço

- Tamanho (Size) – maior peso positivo
- Condomínio (Condo)
- Localização (latitude/longitude)



## Diminuem o Preço

- Algumas variáveis apresentam peso negativo no modelo
- Pesos diferem entre venda e aluguel

## Conclusões do Projeto

A regressão linear manual com NumPy demonstrou ser uma abordagem eficaz para introduzir conceitos fundamentais de aprendizado de máquina:

- Análise exploratória guia a seleção de features
- Localização geográfica tem impacto significativo no preço
- Modelos separados para venda e aluguel capturam dinâmicas distintas do mercado
- O MAE oferece interpretabilidade direta em reais

- ❏ Próximos passos: regularização (Ridge/Lasso), normalização de features e modelos não-lineares para reduzir o MAE.